

1a) Contrastive Learning, Noise Contrastive Estimator Loss است که به سبب زیر است؟

$$NCE_{loss} = -\log \frac{\exp(\text{sim}(g(x), g(x^+)))}{\exp(\text{sim}(g(x), g(x^+))) + \sum_{k=1}^K \exp(\text{sim}(g(x), g(x_k^-)))}$$

در SimCLR، موارد مشابه هم از تابع Loss هایی به این فرم استفاده می کنند و چون داده ها بدون برچسب هستند، برای تشکیل تابع هزینه نیاز به Negative Pair ها دارند. این فرم تابع هزینه ها باعث می شود Positive Pair ها بازخوردی نزدیک صفر بگیرند و Negative Pair ها را مجبور به جدا شدن و متشنج شدن از یکدیگر بکند.

اگر Negative Pair ها نبودند (یعنی عبارت خروجی از تابع Loss وجود نداشت) یک راه ساده این بود که SimCLR حجم بازخوردی صاف یک نقطه ببرد که این معیشت.

(b) مشکل SimCLR در صورت استفاده نادر از Negative Pair ها این است که در بعضی به مثل کسین کردن تمام بازخوردی ها ممکن است میسر نشود. B4OL به نوع این مشکل که بازخوردی ها یکسان شود، از Negative Pair ها استفاده نمی کند. برای این کار، از فیکس در نظر گرفتن هدف target و عبور کردن گرادیان از این هدف استفاده می کند و گرادیان فقط از شاخه online عبور می کند تا بازخوردی view 1 به بازخوردی view 2 نزدیک تر شود. (asymmetric است)

(c) به توجه به اینکه B4OL از Negative examples استفاده نمی کند برای همین اختلاص در نسبت به batch size کوچکتر مقادیر نیاز دارد. دلیل وجود batch normalization در encoder برای بچ های کوچک (در Paper، بچ های 128 نسبت به 256 بسیار انت داشته اما از 256 تا 4096 نسبت ثابت است) است. عملکرد را در هم چین در Paper ذکر می کنند که B4OL سعی در حفظ اطلاعات شبکه target برای بهبود پیش بینی های شبکه ای آنلاین دارد بنابراین حتی اگر augmented view های یک تصویر به اطلاعات کمتری color histogram هم قابل تشخیص باشند، B4OL هم چنان می تواند اطلاعات اضافی برای بازخوردی را نگه دارد.

(d) crop های بهینه کوچک از تصاویر ممکن است شامل اطلاعات متفاوتی از یکدیگر باشند برای همین در Paper معرزشه برای رفع این مشکل سعی به اتریش فیلدهای بازخوردی های crop های بهینه کوچک (دری فقط diversity بازخوردی های local objects) (local crops) و نزدیک کردن بازخوردی های local و global و crop ها در همین زمینه می بین global crop ها دارد. (برای view invariance)

(a)

1	2	3	4	5	6	7	8	میز
1	1	1	1	1	1	1	1	1
1	2	2	2	3	2	2	1	1
2	3	4	5	5	5	3	2	3
3	6	8	9	13	8	7	3	(5)

گراف ست چپ

1	2	3	4	5	6	7	8	9	میز
1	1	1	1	1	1	1	1	1	1
1	2	2	2	3	3	2	2	2	1
2	3	4	5	6	7	5	5	4	3
3	6	8	10	15	16	11	11	10	(6)

گراف ست راست

۳ لایه برای متناظر شدن با انتخابی کرده میزنه نیاز است.

$$M = D^{-1}A = \begin{bmatrix} \frac{1}{2} & 0 & 0 & 0 \\ 0 & \frac{1}{2} & 0 & 0 \\ 0 & 0 & \frac{1}{3} & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

ماتریس انتقال  $\rightarrow M = \begin{matrix} & \begin{matrix} 1 & 2 & 3 & 4 \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \end{matrix} & \begin{bmatrix} 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ \frac{1}{3} & \frac{1}{3} & 0 & \frac{1}{3} \\ 0 & 0 & 1 & 0 \end{bmatrix} \end{matrix}$

stationary Distribution :

$$\sum_{i \in V} \pi(i) = 1$$

$$\pi(i) = \frac{\deg(i)}{\sum_{j \in V} \deg(j)} = \frac{\deg(i)}{2|E|}$$

$$\Rightarrow \pi = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} & \frac{3}{8} & \frac{1}{8} \end{bmatrix}$$

(b)

$$h_i^{L+1} = \frac{1}{|N_i|} \sum_{j \in N_i} h_j^L \rightarrow h_i^{L+1} = D^{-1} A \quad (i)$$

$$h_i^{L+1} = \frac{1}{2} h_i^L + \frac{1}{2|N_i|} \sum_{j \in N_i} h_j^L \rightarrow h_i^{L+1} = \frac{1}{2} (\bar{I} + D^{-1} A) \quad (ii)$$

استفاده است: Deeper insight Graph convolutional networks for semi-supervised Learning  
Qimaili, ...

در این سوال از Notation معیار

$$\begin{aligned} h^{L+1} &= D^{-1} A h^L \\ &= D^{-1} (D + A - D) h^L \\ \xrightarrow{L=A-D} &= (I + D^{-1} L) h^L \\ \xRightarrow{L_{rw}=D^{-1}L} &\Rightarrow h^{L+1} = \lim_{L \rightarrow \infty} (I - L_{rw})^L h^0 \end{aligned}$$

در مقاله ثابت می شود که اگر گراف متصل اجزای دو بخشی نباشد، ترکیب گراف چندگانه به یک ترکیب خطی همگرا می شود:  $(\{1^{(i)}\}_{i=1}^K, \{\theta_i\}_{i=1}^K)$

$$1_z^{(i)} = \begin{cases} 1, & v_z \in c_i \\ 0, & v_z \notin c_i \end{cases} \rightarrow \theta \in \mathbb{R}^n \text{ مشخص می کند که نمودار در مولفه } c_i \text{ وجود دارد یا خیر}$$

$$\Rightarrow \lim_{L \rightarrow \infty} (I - L_{rw})^L h^0 = [1^{(1)}, 1^{(2)}, \dots, 1^{(K)}] \theta$$

اثبات: فرض کنید  $v_k$  به دار ویژه  $L_{rw}$  باشد، آنگاه  $(I - L_{rw})v_k = v_k - \lambda_k v_k = (I - \lambda_k)v_k$  یعنی مقادیر ویژه  $\lambda_k$  مقادیر  $(I - L_{rw})$  برابر  $I - \lambda_k$  است.

مقادیر ویژه  $L_{rw}$  را می توان به صورت  $\lambda_k = \frac{1}{2}(\lambda_k + \lambda_k^*)$  نوشت. مقادیر ویژه  $L_{rw}$  بین  $[-1, 1]$  هستند.  $\lambda_k$  بزرگترین مقدار ویژه مربوط به مقدار ویژه 0 در  $L_{rw}$  است و به دار ویژه هر تبیف با آن  $1^{(i)}$  پس مقادیر ویژه  $(I - L_{rw})$  بین  $[0, 1]$  هستند.  $\lim_{L \rightarrow \infty} (I - L_{rw})^L h^0 = \lim_{L \rightarrow \infty} U \Lambda^L U^{-1} = [1^{(1)}, 1^{(2)}, \dots, 1^{(K)}] \theta$  است.

(e) در آلو، سیستم BFS، استفاده از 1-hop neighborhood نیاز داریم بنابراین GCN یک رایج‌گانی است. Aggregation method:

$$m_u^L = \text{AGGREGATE}(\{h_v^L, v \in N(u)\}) = \max\{h_v^L | v \in N(u)\}$$

update:

$$h^{L+1} = \max\{h_v^{(L)}, m_u^L\} \rightarrow \text{حکمی سبک بازنویس، embedding آن است.}$$

یا سبک از همسایه‌ها، باز در هر مرحله عملی انجام می‌دهد.